

# **Edició de vídeo multicàmera amb self-attention i embeddings temporals i de càmera**

**Òscar Casals Morro**

Nom del Programa  
Àrea 4

**Tutor/a de TF**

Ismael Benito Altamirano

**Professor/a responsable de  
l'assignatura**

David Masip

Data Lliurament  
05/2026

Universitat Oberta  
de Catalunya



Aquesta obra està subjecta a una llicència de  
[Reconeixement-NoComercial-SenseObraDerivada 3.0](https://creativecommons.org/licenses/by-nc-nd/3.0/es/)  
[Espanya de Creative Commons](https://creativecommons.org/licenses/by-nc-nd/3.0/es/)

# Fitxa del Treball Final

|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |                                         |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------|
| <b>Títol del treball:</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | Edició de vídeo multicàmera             |
| <b>Nom de l'autor/a:</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | Òscar Casals Morro                      |
| <b>Nom del Tutor/a de TF:</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        | Ismael Benito Altamirano                |
| <b>Nom del/de la PRA:</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | David Masip                             |
| <b>Data de lliurament:</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 05/2026                                 |
| <b>Titulació o programa:</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | Màster en Data Science                  |
| <b>Àrea del Treball Final:</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       | Àrea 4                                  |
| <b>Idioma del treball:</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | Català                                  |
| <b>Paraules clau</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 | Multicàmera, self-attention, fotograma. |
| <b>Resum del Treball</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |                                         |
| <p>Quan es treballa en sistemes multicàmera és molt important seleccionar el punt de vista correcte a mostrar en cada fotograma, amb l'objectiu d'agilitzar aquest procés, en aquest treball es crearà un model capaç de suggerir quina càmera utilitzar en cada moment del vídeo.</p> <p>Per a crear aquest model, es replicarà el model descrit a l'article "<i>Improving Multi-Camera View Recommendation with Temporal and Camera Embedding</i>" amb dos <i>backbones</i>, i es determinarà quin dels dos és el més indicat.</p> <p>Als resultats s'espera obtenir un model que pugui seleccionar els fotogrames a utilitzar en cada moment.</p> |                                         |
| <b>Abstract</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |                                         |
| <p>When working with multicamera systems, it is very important to select the correct viewpoint to display in each frame. To streamline this process, this work will create a model capable of suggesting which camera to use at every moment of the video.</p>                                                                                                                                                                                                                                                                                                                                                                                       |                                         |

To create this model, the architecture described in the article "*Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*" will be replicated with two backbones, and at the end of the project the most suited for the task will be determined.

Results are expected to yield a model that can select the frames to use at each moment as precisely as the model described in the aforementioned article.

# Index

|                                                                   |           |
|-------------------------------------------------------------------|-----------|
| <b>1. Introducció</b>                                             | <b>1</b>  |
| 1.1. Context i justificació del Treball                           | 1         |
| 1.2. Objectius del Treball                                        | 3         |
| 1.3. Impacte en sostenibilitat, ètic-social i de diversitat       | 3         |
| 1.4. Enfocament i mètode seguit                                   | 5         |
| 1.5. Planificació del Treball                                     | 6         |
| 1.6. Breu sumari de productes obtinguts                           | 7         |
| 1.7. Breu descripció dels altres capítols de la memòria           | 8         |
| 1.8. Declaració sobre l'ús d'intel·ligència artificial generativa | 8         |
| <b>2. Estat de l'art</b>                                          | <b>9</b>  |
| <b>3. Materials i mètodes</b>                                     | <b>16</b> |
| <b>4. Resultats</b>                                               | <b>26</b> |
| <b>2. Conclusions i treballs futurs</b>                           | <b>35</b> |
| <b>3. Glossari</b>                                                | <b>40</b> |
| <b>4. Bibliografia</b>                                            | <b>41</b> |

# 1. Introducció

## 1.1. Context i justificació del Treball

Un sistema multicàmera és un mètode de rodatge on diverses càmeres enfoquen un plató o escena i la graven simultàniament. Posteriorment, en l'edició, de cada càmera es selecciona el millor moment creant un únic vídeo.

Aquests sistemes són essencials per a poder transmetre concerts, shows de televisió i esports; esdeveniments on la franja de temps des que es realitza la gravació en viu fins que es retransmet a televisió o es ven és molt curta.

Adicionalment, aquesta metodologia també és força utilitzada en pel·lícules i sèries amb l'objectiu de poder contemplar cada angle i seleccionar el millor en el procés d'edició, sense haver de tornar a gravar una escena en cas que hagi quedat malament.

Tot i així, aquesta forma de treballar presenta un gran problema, i és que és molt laboriosa.

Com que seleccionar el millor punt de vista a mostrar a l'hora de combinar la informació de les diferents càmeres en un sol vídeo és molt important per a l'experiència de l'espectador, es necessita una gran quantitat de personal especialitzat que pugui mirar les gravacions de cada càmera durant hores i, fent ús de principis cinematogràfics com anar d'un pla general a un de més específic, triar el que millor correspongui a cada moment.

Fins ara, no hi havia cap solució a aquest dilema que fes ús de les avantatges que donen aquests entorns o suficientment robusta com per ser implementada en un entorn professional.

Tanmateix, amb els avenços recents que hi ha hagut en Deep Learning en els últims anys, es podria agilitzar aquest procés?

Això és el que es proposa en el paper *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows*<sup>[1]</sup>, on generen un conjunt de dades compost per diversos vídeos sense editar de quatre escenaris diferents: concerts, esdeveniments esportius, gales i concursos; amb el qual entrenen un model capaç de seleccionar el fotograma correcte en cada moment en un entorn multicàmera.

El conjunt de dades creat en aquest paper s'ha utilitzat per entrenar altres models que busquen millorar els resultats obtinguts, com per exemple el paper *Pseudo Dataset Generation for Out-of-Domain Multi-Camera View Recommendation*<sup>[2]</sup>, on es busca expandir el conjunt de dades prèviament esmentat simulant entorns multicàmera via *clustering*, o l'article "*Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*"<sup>[3]</sup>, on es proposa una arquitectura menys costosa que la utilitzada en el primer paper esmentat.

En aquest treball es busca utilitzar el dataset per a crear un model capaç de suggerir el punt de vista a mostrar en un entorn multicàmera com els descrits en els papers anteriors amb l'objectiu d'agilitzar la feina dels editors de vídeos.

Per a la creació del model, s'ha pres de referència el descrit a *Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*<sup>[3]</sup> recreant-lo amb dos *backbones* diferents, el *swinv2\_tiny\_window8\_256*<sup>[4]</sup> i un de menys potent anomenat *mobilenetv3\_small\_100.lamb\_in1k*<sup>[5]</sup>. Aquesta decisió ha sigut presa amb l'objectiu de veure si l'elecció de backbone impacta en els resultats.

A nivell personal, el treball busca aplicar els coneixements obtinguts a l'assignatura de Deep Learning del màster en Data Science en un cas pràctic.

## 1.2. Objectius del Treball

- Desenvolupar un model capaç de decidir en un moment concret d'un vídeo multicàmara quin punt de vista mostrar.
- Comparar el model final amb *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows*<sup>[1]</sup> i veure si els resultats són similars als obtinguts en "Improving Multi-Camera View Recommendation with Temporal and Camera Embedding"<sup>[3]</sup>.
- Entrenar el model amb dos backbones diferents, i determinar si hi ha un impacte en els resultats.
- Avaluar la qualitat del model final.

## 1.3. Impacte en sostenibilitat, ètic-social i de diversitat

### Sostenibilitat:

Com es menciona en el paper *The green paradox: The climate, environmental, and sustainability implications of artificial intelligence*<sup>[6]</sup>, el ràpid progrés de la intel·ligència artificial està tenint un impacte mediambiental bastant gran, això és degut a:

- La ràpida creació de centres de dades i grans models augmenta la demanda de recursos bàsics com l'electricitat, aigua, minerals...
- La infraestructura i el funcionament d'aquests centres de dades també augmenten les emissions de CO<sub>2</sub>

No obstant això, aquesta despesa energètica s'aplica a models que utilitzen milions de dades i depenen d'aquestes infraestructures per operar.

El model desenvolupat en aquest treball no requereix tants recursos com els esmentats pel fet que pot ser executat des d'un ordinador mínimament potent.

Addicionalment, s'ha escollit una arquitectura bastant lleugera, cosa que redueix encara més el poc impacte que el treball realitzat pogués tenir sobre el medi ambient.

#### Comportament ètic i de responsabilitat social (RS):

Des del punt de vista social, el treball no posa en perill cap ocupació, sinó que n'agilitza les existents, pel fet que el resultat és un model que recomana quin fotograma utilitzar quan s'està editant un vídeo multicàmera.

Decisions com quan fer un canvi de pla o si l'elecció del model és veritablement la correcta estan en mans d'un editor professional.

Assolir els objectius del projecte, però, podria transformar la dinàmica de treball en entorns multicàmera, ja que els editors no haurien de centrar-se en decidir quin és el fotograma més òptim a l'hora de canviar de pla, sinó en avaluar si l'elecció del model encaixa i en decidir quin és el millor moment del vídeo per a realitzar un canvi de càmera.

Des del punt de vista ètic, el projecte no promou comportaments ètics o no ètics, el model desenvolupat simplement selecciona el punt de vista més indicat en cada moment en un entorn multicàmera. Per tant, la moralitat de l'ús dels resultats obtinguts recau intrínsecament en l'usuari.

#### Diversitat, gènere i drets humans.

Atès que el model pretén seleccionar el fotograma més indicat en cada moment d'un vídeo multicàmera, no pot ser utilitzat per cap persona amb una discapacitat visual prou gran com per no poder distingir entre diferents plans.

Aquest problema és intrínsec a la naturalesa del treball i, per tant, no s'intenta solucionar.

Respecte a factors com el gènere o l'ètnia influint en les decisions del model, en cap dels papers consultats per a aquest projecte on s'utilitza el dataset amb el qual s'entrenarà el model, el TVMCE, es mencionen biaixos cap a cap

col·lectiu, el que dona indicis de que el model resultant no hauria de discriminar a ningú.

Al treball no s'incumpleix cap propietat intel·lectual degut a que en tot moment s'acredita d'on provenen els recursos externs. Tenint en compte això, el producte desenvolupat s'ha pensat per agilitzar la tasca d'editors de vídeo en entorns multicàmera, el que implica que és responsabilitat de l'usuari que el vídeo que produeix no incompleixi cap legislació.

## 1.4. Enfocament i mètode seguit

Per a aquest treball es replicarà el model descrit a “Improving Multi-Camera View Recommendation with Temporal and Camera Embedding”<sup>[3]</sup> i es compararà amb els resultats descrits a “*Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows*”<sup>[1]</sup>


La raó per la que s'ha optat replicar aquesta arquitectura és degut a que:

- Presenta un temps d'entrenament relativament petit en comparació a altres models que busquen solucionar el mateix problema.
- La seva *accuracy* és superior al previ model SOTA quan es va publicar el paper.
- Com la seva arquitectura no requereix de grans recursos, es pot desenvolupar en un entorn amb un nivell de computació que no estigui al nivell de clusters.

Per a l'extracció de característiques de cada fotograma, es provaran dos *backbones*, el *swinv2\_tiny\_window8\_256*<sup>[4]</sup> i un de menys potent anomenat *mobilenetv3\_small\_100.lamb\_in1k*<sup>[5]</sup>.

La raó d'aquesta decisió és determinar si utilitzar un backbone menys potent afecta significativament els resultats o, per contra, podria substituir al que requereix més recursos reduint els requeriments tècnics necessaris per a l'ús del model obtingut.

## 1.5. Planificació del Treball



| Nom                                                                                                                                | Data d'inici | Data final | Duració (dies) |
|------------------------------------------------------------------------------------------------------------------------------------|--------------|------------|----------------|
| Definir projecte amb el tutor                                                                                                      | 1/13/26      | 1/13/26    | 1              |
| Buscar dataset                                                                                                                     | 1/14/26      | 1/20/26    | 5              |
| Llegir papers on citen TVMCE.                                                                                                      | 1/21/26      | 2/19/26    | 22             |
| Mòdul 1 - Fer Abstract i capítol 1 de la memòria                                                                                   | 2/20/26      | 2/27/26    | 6              |
| Començar a treballar en un notebook de kaggle                                                                                      | 3/2/26       | 3/9/26     | 6              |
| Provar notebook amb subsample del TVMCE                                                                                            | 3/10/26      | 3/12/26    | 3              |
| Mòdul 2 - Estat de l'art                                                                                                           | 3/13/26      | 3/20/26    | 6              |
| Finalitzar el notebook, Executar notebook amb dataset sencer.<br>En cas que doni temps, quantificar extractor de característiques. | 3/23/26      | 4/23/26    | 24             |
| Mòdul 3- Fer capítol 2 i 3 de la memòria                                                                                           | 4/24/26      | 5/8/26     | 11             |
| Finalitzar memòria i entrega preliminar                                                                                            | 5/11/26      | 5/15/26    | 5              |
| Pulir memòria i entregar-la                                                                                                        | 5/18/26      | 5/22/26    | 5              |

## 1.6. Breu sumari de productes obtinguts

En aquest treball s'ha desenvolupat un model capaç de suggerir quin punt de vista mostrar en cada moment en un entorn multicàmera.

Com que no hi ha una implementació pública de cap model que pugui resoldre la problemàtica actualment, aquest projecte també busca crear-ne una que pugui servir de base per a que altres persones desenvolupin els seus propis projectes innovant en el panorama.

El model que s'ha desenvolupat es basa en el presentat a *Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*.

Si s'aconsegueixen complir els objectius, d'una banda es reduiria el temps necessari per elaborar un únic vídeo a partir de múltiples punts de vista, ja que, en comptes de tenir un grup de professionals revisant durant hores diverses càmeres per decidir quina és la millor perspectiva a mostrar, el model obtingut realitza la recomanació directament i aquests només hauran de revisar les altres càmeres quan no estiguessin d'acord amb l'elecció.

Per altra banda, s'obté una implementació pública del model presentat a *Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*<sup>[3]</sup>, que podria servir de plantilla per a desenvolupar altres models o com a punt de partida per a millorar el panorama existent en l'edició automàtica de vídeos multicàmera

## 1.7. Breu descripció dels altres capítols de la memòria

- **Capítol 2:** Es parlarà de l'estat de l'art, és a dir, els papers previs a aquest treball que han abordat la problemàtica.
- **Capítol 3:** Es descriurà com funciona l'arquitectura del model creat i es justificaran diverses decisions preses al projecte.
- **Capítol 4:** Es calcularan les mètriques necessàries per mirar la qualitat del model.
- **Capítol 5:** S'extreuen les conclusions del treball, s'analitzarà la planificació seguida durant el projecte, i es miraran les línies de treball a futur que no s'han pogut explorar.
- **Capítol 6:** Es definiran els termes i acrònims més rellevants en la memòria.
- **Capítol 7:** Bibliografia.

## 1.8. Declaració sobre l'ús d'intel·ligència artificial generativa

Per a aquest treball s'ha utilitzat intel·ligència artificial Gemini per a produir la figura 5 durant la redacció de la memòria.

Per a crear-la, se li ha descrit a Gemini com funciona l'extractor de característiques emprat en el model i se li ha demanat que l'esquematitzés.

La imatge creada per Gemini posteriorment ha sigut editada per a reduir la quantitat d'informació que mostrava.

## 2. Estat de l'art

Els sistemes multicàmera són essencials per al desenvolupament de la majoria de contingut audiovisual actualment. Aquesta tècnica consistent en gravar una mateixa escena des de múltiples punts de vista i després utilitzar els millors angles per a produir un únic vídeo és força utilitzada en esports, gales, concursos, concerts...

Aquesta metodologia, però, presenta un gran problema, i és el temps requerit per produir-ne el vídeo final.

Crear un vídeo a partir de múltiples fonts requereix d'un professional que observi durant hores cada un dels fotogrames recollits per les diferents càmeres, i seleccioni el millor per a cada moment. Aquesta elecció no es basa només en el contingut de cada candidat, sinó també en els fotogrames ja seleccionats per al vídeo final i en principis cinematogràfics com els següents, descrits al llibre *The technique of film editing*<sup>[7]</sup>:

- No mostrar el mateix punt de vista durant molt de temps.
- Introduir una escena nova des d'un punt de vista general i anar progressant cap a un més proper a l'acció principal.

A la figura 1 es pot veure un exemple del procés d'edició en entorns multicàmera generat amb el TVMCE dataset.

En l'exemple, es pot observar com el vídeo progressa des d'un punt de vista general a un més proper, com es descriu en els principis cinematogràfics anteriors.



**Figura 1:** Representació del procés d'edició en un entorn multicàmera  
extret del TVMCE dataset<sup>[1]</sup>.

Amb els avenços recents en machine learning, concretament en Deep Learning, s'han desenvolupat diversos models que busquen agilitzar aquest procés.

A l'hora de desenvolupar-los, però, hi ha una gran problemàtica, que és la manca de conjunts de dades públics amb gravacions de diferents càmeres i el vídeo final amb els fotogrames seleccionats. Això dificulta molt realitzar l'entrenament d'un model.

Alguns papers com *Real Time GAZED: Online Shot Selection and Editing of Virtual Cameras From Wide-Angle Monocular video Recordings*<sup>[8]</sup> eviten el problema completament simulant múltiples càmeres a partir d'un pla general, tallant l'escena en fragments i seleccionant el millor per a cada moment.

Aquesta aproximació, però, està pensada per produccions on només es disposa d'un sol punt de vista general i, per tant, no contempla escenaris on hi ha més d'una càmera situada al voltant de l'escena.

Una altra solució possible és la proposada al paper *Pseudo Dataset Generation for Out-of-domain Multi-Camera View Recommendation*<sup>[2]</sup> on s'augmenta la mida de *datasets* multicàmera existents a través de vídeos líneals ja editats.

La metodologia utilitzada en aquest paper es basa en dos fets:

- Molts canvis de pla en un vídeo són el resultat de canvis de càmera.
- En un entorn multicàmera, les càmeres són estacionàries i són responsables de gravar perspectives a diferents escales (des de generals a més properes a una acció).

Gràcies a aquests dos punts és possible realitzar *clustering* dels diferents fotogrames que componen un vídeo, assignant a cada membre d'un grup la mateixa etiqueta, que correspon a la "càmera" que representen, a la que a partir d'ara anomenarem pseudo-càmera.

Un cop creat un entorn on diferents pseudo-càmeres existeixen, cal definir els diferents candidats entre els quals, en un entorn multicàmera real, s'hauria d'escollir per a produir un vídeo final. Aquest procés es realitza de la forma següent:

1. S'extreuen les característiques de cada imatge utilitzant la xarxa neuronal ResNet50<sup>[9]</sup> pre-entrenada amb ImageNet<sup>[10]</sup>.
2. Es realitza *cosine-similarity* entre els components de les diferents pseudo-càmeres, els fotogrames més similars entre diferents grups són els candidats, i el fotograma que s'utilitza en el *timestamp* que s'estigui mirant del vídeo original és el seleccionat que el model haurà de predir.

Aquesta simulació busca millorar la quantitat de casos que cobreixen els datasets ja existents i així millorar la generalització dels models.

Un altre intent de simular entorns multicàmera és el fet a *ReCamMaster: Camera-Controlled Generative Rendering from A Single vídeo*<sup>[11]</sup>, on si bé no busquen desenvolupar un model per seleccionar el millor fotograma en un entorn multicàmera, també es troben amb la problemàtica de la manca de conjunts de dades.

En aquest paper la forma de solucionar el problema és simular entorns multicàmera mitjançant el famós motor gràfic *Unreal Engine 5*<sup>[12]</sup>.

El conjunt de dades més complet trobat, però, i el que utilitzen la majoria de referències consultades, és el presentat a *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows*<sup>[1]</sup>, el *TVMCE dataset*.

En aquest paper es presenta un conjunt de dades format per diversos vídeos sense editar de quatre escenaris diferents: concerts, esdeveniments esportius, gales i concursos. Entre tots els escenaris hi ha 88 hores de metratge sense editar gravat des de diverses càmeres diferents, amb les quals es generen vídeos llestos per a emissió televisiva; en total, hi ha 14 hores de vídeos editats.

A partir d'aquest dataset s'han desenvolupat diversos models que aborden el problema d'escollir quin punt de vista és el més indicat per a cada moment en un entorn multicàmera, la majoria tractant-lo com un problema de classificació.

El paper *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows*<sup>[1]</sup> proposa una arquitectura basada en dos transformers, un temporal que processa fotogrames anteriors als considerats, i un contextual que s'encarrega dels fotogrames que s'estan considerant per a un moment concret.


El model proposat, com es pot veure a la figura 2, està compost per dos components:

- **TC-Transformer:**

- S'extreuen les característiques dels fotogrames captats per cada càmera i es guarden en un vector numèric (*feature vector*).
- S'apliquen dos transformadors:
  - Un temporal, que modela la informació històrica utilitzant fotogrames anteriors als candidats.
  - Un contextual, que modela la informació de cada fotograma considerat per a un moment concret, és a dir, els fotogrames candidats.
- Per a l'extracció de característiques (*feature extraction*) s'avaluen dos backbones: el ViViT<sup>[13]</sup> i el vídeo-Swin<sup>[14]</sup> pre-entrenats amb *Kinetics-400*<sup>[15]</sup>, sent el vídeo-Swin<sup>[14]</sup> el que dona millors resultats.

- **Multi-layer perception (MLP):**

- Els resultats dels dos transformadors s'introdueixen com a input en una MLP, que assigna una puntuació a cada candidat en funció de com són d'adequats.



**Figura 2:** Esquema de com funciona el model presentat a *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows* <sup>[1]</sup>.

El model presentat en l'article, però, presenta problemes fora dels dominis amb què s'ha entrenat. Per millorar-ne la generalització, el paper *Pseudo Dataset Generation for Out-of-domain Multi-Camera View Recommendation* busca augmentar la mida del TVMCE dataset artificialment simulant entorns multicàmera mitjançant clustering.

Aquesta aproximació, però, no aconsegueix millorar la generalització del model, tot i que sí que augmenta la seva precisió un 68% en els dominis inclosos en el TVMCE.

La metodologia d'ampliar el *dataset* TVMCE amb entorns multicàmera simulats a partir de vídeos lineals ha sigut emprada en altres treballs que busquen desenvolupar models per a un domini específic, com en *When and How to Cut Classical Concerts? A Multimodal Automated vídeo Editing Approach* <sup>[16]</sup> on s'utilitza per a desenvolupar un model exclusiu per a concerts de música clàssica.

Per altra banda, el paper *Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*<sup>[3]</sup> busca millorar els models descrit anteriorment aplicant dos principis cinematogràfics:

1. No mostrar el mateix punt de vista durant molt de temps.
2. Introduir una escena nova desde un punt de vista general i anar progressant cap a un més proper a l'acció principal.

Per a que el model pugui aprendre aquests dos principis, a l'hora de fer feature extraction dels frames de cada càmera s'afegeix *embeddings* temporals (distància entre els anteriors i el candidat) i el ID de la càmera a la que pertany un fotograma.

Aquesta arquitectura també es caracteritza per no utilitzar un TC-transformer, sinó que relaciona la informació dels fotogrames anteriors a un moment concret i els candidats mitjançant self-attention<sup>[17]</sup>.

Com es veu a la figura 3, l'arquitectura exposada està conformada pels següents components:

- **Feature extraction:**

- S'extreuen les característiques d'un fotograma i es guarden en un vector numèric (feature vector).
- Al vector s'afegeix la següent informació:
  - Quantitat de fotogrames entre el que s'està mirant i el candidat (frame offset) en forma de *positional embedding*.
  - L'identificador de la càmera utilitzada em forma d'embedding.
- El backbone utilitzat és *Swin Transformer*<sup>[18]</sup> pre-entrenat amb *ImageNet*<sup>[10]</sup>.
- Aquest feature extractor s'aplica a tots els fotogrames: els anteriors al moment que s'està considerant i a cada candidat.


- **Past-candidate mixer (Self-attention layer):**

- Es concatenen els *feature vectors* de tots els fotogrames en una sola seqüència.
- Es realitza *self-attention* per afegir context als vectors.

- **Multi-layer perception (MLP):**

- Es seleccionen els vectors amb context corresponents als fotogrames candidats i es donen com a input a una MLP amb la següent arquitectura:

- Una capa de normalització que s'aplica al input.
- Una capa lineal.
- Una funció d'activació GeLU.
- Una última capa lineal.




**Figura 3:** Representació de l'arquitectura descrita a *Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*<sup>[3]</sup>

Aquest framework posseeix una precisió 14% superior al model presentat a *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows*<sup>[1]</sup> i el temps d'entrenament es redueix un 90%.

### 3. Materials i mètodes

Per a l'entrenament i l'avaluació del model s'ha utilitzat el conjunt de dades TVMCE, conformat per 6 arxius *tar*, cadascun emmagatzemant els diferents fotogrames i càmeres que s'utilitzen en un vídeo concret, així com els utilitzats en el resultat final.

El TVMCE té metratge que pertany a les següents categories: gales, concerts, concursos i esports; això el fa bastant indicat com a conjunt d'entrenament degut a que els entorns multicàmera són molt presents en aquests àmbits. A la figura 4 es pot veure la proporció de fotogrames que pertanyen a cada categoria.



**Figura 4:** *Categories del TVMCE dataset*<sup>[19]</sup>. Gràfic fet amb Pie Chart Creator<sup>[20]</sup>.

A part del metratge, aquest *dataset* també posseeix dos JSON. Un inclou les 7265 mostres amb les que es va entrenar el model presentat a *Temporal and Contextual Transformer for Multi-Camera Editing*<sup>[19]</sup> (al que,

a partir d'ara ens referirem com *TC-Transformer* per conveniència) i l'altre en té les 2058 amb les que es va avaluar.

Cada mostra en el JSON conté:

- Els fotogrames anteriors a un moment concret amb el ID de la càmera que s'estava utilitzant (a partir d'ara, ens hi referirem com a fotogrames passats).
- Si s'ha valorat canviar de càmera en aquell moment.
- Els diferents candidats a triar amb l'ID de la càmera d'on ve cadascun.

A partir d'aquestes dades, s'ha calculat per a cada fotograma passat la seva distància temporal amb els candidats (*frame offset*), posteriorment, com en el paper *Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*<sup>[3]</sup> es mostra que els *frames* massa allunyats dels candidats a triar influeixen molt poc en els resultats, s'ha decidit ignorar les imatges que estiguin a més de 500 fotogrames de distància del candidat que s'estigui considerant, reduint cost computacional i soroll.

Adicionalment, atès que l'objectiu d'aquest projecte és desenvolupar un model capaç de seleccionar el punt de vista més adequat al que canviar, i no determinar el moment en què és convenient realitzar un canvi de perspectiva, s'ha aplicat un filtratge sobre el conjunt d'entrenament i test per conservar únicament aquelles entrades on es produeix un canvi de càmera.

Després d'aquest procés, en el conjunt d'entrenament en queden 4034 mostres i en el de validació hi resten 1087.

Per poder comprovar si el model presenta signes d'overfitting durant l'entrenament, s'ha dividit el conjunt d'entrenament en dos *subsets*. El primer conté 90% de les mostres i s'ha utilitzat per entrenar el model, el segon posseeix el 10% i s'ha utilitzat com a conjunt de validació.

En aquest treball no s'ampliarà el *dataset* TVMCE mitjançant clustering, degut a que generar pseudo-vídeos multicàmera amb aquesta tècnica fa perdre informació contextual de cada fotograma que pot portar problemes a l'hora de validar els resultats. Per tant, es considera només la informació present en el propi *dataset*.

Tampoc s'ha tingut en compte el dataset creat a *ReCamMaster: Camera-Controlled Generative Rendering from A Single video*<sup>[11]</sup> perquè per a aquest treball s'ha volgut treballar amb dades de produccions reals i així poder verificar que el model resultant funciona en aquests escenaris.

Per a la construcció i entrenament del model s'ha utilitzat la GPU NVIDIA GeForce RTX 3060 Laptop. El desenvolupament del codi s'ha realitzat en Python mitjançant la llibreria Pytorch<sup>[21]</sup>.

Respecte a la preparació de les dades, inicialment es va optar per utilitzar la llibreria estàndard de Python *tarfile* per accedir directament als arxius comprimits, sense necessitat de descomprimir-los, i així reduir els requeriments d'emmagatzematge necessaris per executar el codi del projecte.

Tanmateix, aquesta metodologia incrementa considerablement el temps de càrrega de les dades i, com a conseqüència, alentia l'entrenament causant un *bottleneck*. Per aquest motiu, finalment s'ha optat per descomprimir prèviament els arxius abans d'iniciar l'entrenament del model.

L'arquitectura amb la qual es desenvoluparà el model en aquest projecte és la presentada a *Improving Multi-Camera View Recommendation with Temporal and Camera Embedding*<sup>[3]</sup>, degut a que presenta un temps d'entrenament menor als descrits pel model exposat a *Temporal and Contextual Transformer for Multi-Camera Editing of TV Show*<sup>[19]</sup> i resultats més precisos.

Aquesta arquitectura es caracteritza per incloure el *frame offset* i el ID de la càmera en el vector amb les característiques extretes d'un fotograma, permetent al model aprendre els següents principis cinematogràfics:

- No mostrar la mateixa càmera durant molt de temps.
- Introduir una escena des d'un punt de vista general i anar progressant gradualment a perspectives més concretes.

A més a més, gràcies a que s'inclou el *frame offset* i el ID de la càmera en el *feature vector* d'un fotograma, es pot prescindir del transformador temporal i contextual que formen el TC-Transformer, utilitzant com a alternativa *self-attention* per a incloure informació temporal i contextual al model.

Això redueix el temps d'entrenament i els recursos emprats tant per a entrenar el model com per a la predicció de fotogrames.

Abans de començar amb la construcció del model però, s'ha utilitzat la classe de pytorch *Dataset* per a crear-ne una capaç de pre-processar els JSON i recuperar les diferents dades requerides per l'extractor de característiques.

Concretament, el pre-processament realitzat per aquesta classe és el següent:

- Eliminar les mostres del JSON rebut on no s'ha considerat un canvi de càmera.
- Calcular el frame offset de cada fotograma i eliminar les mostres on aquest sigui major a 500.
- Quan es vol recuperar una mostra, recollir la següent informació i la retorna en forma de tensor, les variables amb les que Pytorch<sup>[21]</sup> treballa. Concretament recopila:
  - Els fotogrames candidats. Que són escalats a una mida de 256x256 amb l'objectiu de que el backbone pre-entrenat pugui treballar amb ells.

- Els ID de les càmeres amb les que ha sigut captat cada candidat.
- Fotogrames anteriors als candidats.
- El *frame offset* entre cada fotograma i els candidats.
- L'ID de la càmera que s'estava utilitzant fins al moment de canviar.
- L'ID de la càmera corresponent al pla que finalment es va utilitzar al vídeo final.

Com s'observa a la figura 6, el model creat està conformat per tres components principals:

- **Extractor de característiques:**

Aquest component és el primer en executar-se de tota l'arquitectura, i s'aplica per separat als fotogrames candidats i passats.


Rep com input la informació extreta per la nostra classe *Dataset*: els fotogrames, els ID de les càmeres, i el *frame offset*. Retornant un *feature vector* amb el *frame offset* i l'ID de la càmera inclosos. Per a elaborar-ho realitza el següent:

- Extreu característiques del fotograma i les codifica en un vector  $(v)$  amb el transformador *swinv2\_tiny\_window8\_256*<sup>[4]</sup>, concretament, s'ha emprat la versió pre-entrenada amb el dataset *ImageNet-1k*<sup>[22]</sup> inclosa a *timm*<sup>[23]</sup>.
- Afegeix el *frame offset* com a positional *embedding* al vector anterior (*PE*).
- Afegeix l'identificador de la càmera al vector anterior com a un *learnable embedding* (*CAM*).

Gràcies a aquest procés obtenim un *feature vector* (*fv*) que pot ser definit de la forma següent:  $fv = v + PE + CAM$ .

L'avantatge d'aquesta metodologia és que, com *swinv2\_tiny\_window8\_256*<sup>[4]</sup> ja està pre-entrenat amb el dataset *ImageNet-1k*<sup>[22]</sup>, del feature extractor només en tenim que entrenar l'embedding corresponent a la càmera.

A la figura 5 es mostra un esquema de com es troba estructurat el feature extractor.



**Figura 5:** Esquema del extractor de característiques fet amb Gemini

- **Barrejador de fotogrames passats amb fotogrames candidats (capa Self-Attention):**

Un cop s'han generat els diferents *feature vectors*, es concatenen tots ells en un de sol amb l'objectiu de poder aplicar *self-attention*<sup>[17]</sup> sobre la seqüència resultant.

En aplicar *self-attention*<sup>[17]</sup> s'està dotant de context sobre els diferents candidats i els fotogrames anteriors a cada feature vector.

- **Multi Layer Perceptron (MLP):**


Amb tots els vectors amb context obtinguts, s'extreuen aquells corresponents als candidats i, mitjançant una MLP, se'ls hi assigna una puntuació.

Quan més adequat sigui un fotograma, major puntuació en tindrà, i el que més en tingui, és el que es considera el més indicat per ser utilitzat al vídeo final.

Aquesta MLP està conformada per les següents capes:

- Una capa de normalització aplicada a *l'input*.
- Una capa lineal.
- Una funció d'activació GeLU.
- Una última capa lineal.

Com es pot veure a la figura 6, amb aquest disseny els únics components que requereixen entrenament del model són el *camera embedding* de l'extractor de característiques, el barrejador de fotogrames passats i candidats, i la MLP.



**Figura 6:** Arquitectura del model amb les parts que no requereixen d'entrenament marcades amb blau.

Per a entrenar al model, s'ha utilitzat la funció de pèrdua *Binary Cross Entropy* (BCE) mitjançant la funció de *Pytorch BCEWithLogitsLoss*.

Això és degut al fet que, si bé el problema consisteix en seleccionar una càmera entre diverses candidates, el model retorna una puntuació per a cada càmera, el que es pot interpretar com un problema binari on per cada perspectiva només en tenim dues possibles respostes: la càmera és la seleccionada (1) o no (0).

Aquesta metodologia permet utilitzar la funció *loss* BCE, la qual compara les puntuacions generades pel model amb les etiquetes binàries de cada càmera.

L'optimitzador emprat ha sigut AdamW<sup>[24]</sup>, una variant de l'optimitzador Adam àmpliament utilitzada en deep learning.

Finalment, l'entrenament s'ha dut a terme amb un learning rate de  $1e-5$ , 10 epochs i una *batch size* de 4. Aquesta configuració ha permès entrenar el model en un temps relativament reduït i obtenir un resultat bo.

La raó per la qual s'ha escollit una *batch size* de 4 en comptes de 2 com fan papers com *Improving Multi-Camera View Recommendation with Temporal and Camera Embeddings*<sup>[3]</sup> es perquè com es treballa amb recursos limitats, s'ha volgut veure si incrementant lleugerament la *batch size* es redueix el temps d'entrenament i es segueix obtenint uns bons resultats.

Per a mesurar l'efectivitat de l'entrenament i el model, s'han utilitzat les següents mètriques:

- Loss: La diferència entre els valors predits i els reals. Quan més proper a 0, més similars són els resultats als valors reals.
- Accuracy: Mesura la proporció de prediccions encertades respecte el total. Es calcula de la forma següent:

$$\frac{\text{Prediccions encertades}}{\text{Nombre de prediccions}}$$

- Precisió: Mesura la fiabilitat de les prediccions del model.

Tenint en compte que en aquest cas els veritables positius són les vegades en què una càmera ha sigut seleccionada correctament, i els falsos positius els cops on aquesta ha sigut triada erròniament.

Es calcula de la forma següent:

Veritables positius

---

Veritables positius + Falsos positius

- *Recall* (sensitivitat): Mesura la capacitat del model d'identificar la càmera correcta.

Tenint en compte que en aquest escenari els falsos positius es corresponent a totes aquelles vegades on s'ha descartat erròniament una càmera, es calcula de la forma següent:

Veritables positius

---

Veritables positius + Falsos negatius

- Puntuació F1: Mesura l'equilibri entre precisió i *recall*. Es calcula de la forma següent:

$$2 * \left( \frac{\text{Precisió} * \text{Recall}}{\text{Precisió} + \text{Recall}} \right)$$

- Matriu de confusió: Visualització que mostra les prediccions correctes i errònies en forma de matriu, és a dir: els veritables positius i negatius, així com els falsos positius i negatius.

Per a mesurar l'impacte del backbone en els resultats, s'ha entrenat una altra versió del model utilitzant *mobilenetv3\_small\_100.lamb\_in1k*<sup>[5]</sup> pre-entrenat amb *ImageNet-1k*<sup>[22]</sup>, en comptes de *swinv2\_tiny\_window8\_256*<sup>[4]</sup>, en l'extractor de característiques.

La principal raó per la qual s'ha escollit *mobilenetv3\_small\_100.lamb\_in1k*<sup>[5]</sup> com a backbone alternatiu és que, com aquest model ha estat pensat per a ser utilitzat en tel·lèfons mòbils, en cas d'obtenir resultats similars als observats amb *swinv2\_tiny\_window8\_256*<sup>[4]</sup> es reduirien bastant els requeriments tècnics necessaris per a utilitzar el model i, a més a més, permetria realitzar el

primer pas de l'extractor de característiques a mesura que es van captant els fotogrames; reduint el temps necessari per a cada inferència.

Addicionalment, també s'ha escollit aquest backbone com a alternatiu perquè, com també està present a *timm*<sup>[23]</sup>, la implementació dels dos backbones no requereix de gaires canvis al codi.

El codi utilitzat, juntament amb una versió exportada al format onnx del model amb backbone SwinV2, es pot trobar al següent github:

[https://github.com/ocasalsmo/Edicio\\_de\\_video\\_multicamera](https://github.com/ocasalsmo/Edicio_de_video_multicamera)

## 4. Resultats

Al final de tot el procés s'ha obtingut un model capaç de recomanar el punt de vista més indicat en un entorn multicàmera.

L'entrenament amb el backbone *swinv2\_tiny\_window8\_256*<sup>[4]</sup> ha durat 1 hora 49 minuts, mentre que en el model amb *mobilenetv3\_small\_100.lamb\_in1k*<sup>[5]</sup> la duració ha sigut de 1 hora 21 minuts.

Com es pot veure a la figura 7, els dos temps són similars als mostrats al paper *Improving Multi-Camera View Recommendation with Temporal and Camera Embeddings*<sup>[3]</sup> i bastant inferior al TC Transformer.


| Model                                                                                                                                                           | Temps d'entrenament     |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------|
| TC Transformer                                                                                                                                                  | 28 hores                |
| Model amb <i>embeddings</i> temporals i de càmera (Paper <i>Improving Multi-Camera View Recommendation with Temporal and Camera Embeddings</i> <sup>[3]</sup> ) | 2 hores 5 minuts        |
| <b>Model amb <i>embeddings</i> temporals i de càmera (<i>mobilenetv3_small_100.lamb_in1</i><sup>[5]</sup>)</b>                                                  | <b>1 hora 21 minuts</b> |
| <b>Model amb <i>embeddings</i> temporals i de càmera (<i>swinv2_tiny_window8_256</i><sup>[4]</sup>)</b>                                                         | <b>1 hora 49 minuts</b> |

**Figura 7:** Temps d'entrenament de cada model, per als models dels papers s'han pres les dades del *Improving Multi-Camera View Recommendation with Temporal and Camera Embedding* <sup>[3]</sup>, on executen els dos models en un entorn amb GeForce RTX 2080 Ti i una mida de batch de 2.


La diferència de temps entre el nostre model entrenat amb Swinv2 i el presentat en el paper *Improving Multi-Camera View Recommendation with Temporal and Camera Embeddings* pot ser explicada pel fet que, per una banda, en aquest projecte s'ha utilitzat la versió tiny del backbone, la qual és molt més lleugera; i per una altra, la mida de cada batch és major.

Per a mesurar l'efectivitat de l'entrenament, s'han utilitzat dues mesures: la pèrdua (*loss*) i l'*accuracy*.

A les figures 8 i 9 es pot veure com *accuracy* i *loss* en el conjunt d'entrenament i validació són similars en cada *epoch*. Això suggereix que no hi ha indicis de sobre-entrenament en cap dels dos models obtinguts.



**Figura 8:** *Loss i Accuracy en el conjunt d'entrenament per cada epoch en el model amb Swinv2 com a backbone.*



**Figura 9:** *Loss i Accuracy en el conjunt d'entrenament per cada epoch en el model amb MobileNetV3 com a backbone.*

A la figura 10 es poden veure les diferents mètriques de qualitat que s'han obtingut en utilitzar el model sobre el conjunt de test.

| Mètrica         | Valor (SwinV2) | Valor (MobileNetV3) |
|-----------------|----------------|---------------------|
| <i>Accuracy</i> | 71.21%         | 43'05%              |
| <i>Loss</i>     | 0.28           | 0.49                |
| Precisió        | 68.75%         | 41.63%              |
| <i>Recall</i>   | 69.41%         | 38.43%              |
| Puntuació F1    | 68.45%         | 36.35%              |

**Figura 10:** Mètriques de qualitat del model amb els dos backbones.

L'accuracy amb el backbone SwinV2 és força alta, mostrant que la majoria de resultats han sigut predits correctament.

En canvi, l'accuracy amb el backbone MobileNetV3 és molt més baixa. Aquesta diferència indica que el backbone impacta en la quantitat d'eleccions encertades pel model.

La precisió obtinguda amb el backbone SwinV2 és propera a 70%, el que indica que la majoria de prediccions fetes per el model són fiables.

En canvi, la vista amb el backbone MobileNetV3, és molt més baixa, demostrant que aquest backbone impacta negativament en la fiabilitat de les eleccions fetes pel model.

A la figura 11 es pot veure que les dos precisions obtingudes són més altes que les mostrades en el paper on es presenta el TC-Transformer.

| Model                                                                  | Precisió(%) |
|------------------------------------------------------------------------|-------------|
| TC-Transformer(ViVi)                                                   | 21.29       |
| TC-Transformer(Swin)                                                   | 22.48       |
| <b>Model amb <i>embeddings</i> temporals i de càmera (MobileNetV3)</b> | 41.63       |
| <b>Model amb <i>embeddings</i> temporals i de càmera (SwinV2)</b>      | 68.75       |

**Figura 11:** *Precisió del model obtingut i la reportada a Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows<sup>[19]</sup> per als dos backbones provats.*

El *Recall* mitjà calculat per al model amb backbone SwinV2 és similar a la precisió i proper a 70%, el que és un indicatiu de que el model en la majoria dels casos és capaç de detectar el punt de vista correcte.


Similar al vist amb les dues mètriques anteriors, la sensibilitat del model amb backbone MobileNetV3 és molt inferior, reforçant que el canvi de backbone ha tingut un impacte negatiu.

Finalment, es pot observar que la puntuació F1 calculada per al model amb SwinV2 com a backbone és similar als valors vistos en la precisió i la sensibilitat, resultant propera a 70%. Aquest resultat indica que el model presenta un bon equilibri entre la fiabilitat dels resultats i la seva capacitat de detectar el punt de vista més indicat.

Igual que amb les altres mètriques, el model amb MobileNetV3 com a backbone presenta una puntuació F1 inferior, demostrant l'impacte negatiu que ha tingut el canvi de backbone.

Per a veure si alguna càmera presenta més errors que les altres en la predicció, també s'ha creat una matriu de confusió sobre els resultats del model amb backbone SwinV2.

Com es pot veure a la figura 12, tot i que per a totes les càmeres la majoria de prediccions han sigut correctes, les càmeres 4 i 5 són les que més errors presenten. La majoria d'equivocacions respecte a aquestes dues càmeres són degudes a que el model ha considerat més indicats els fotogrames de la càmera 2 per sobre dels que han captat les càmeres 4 i 5.



**Figura 12:** Matriu de confusió del model amb backbone SwinV2

Finalment, s'ha buscat complementar la informació proporcionada a la matriu de confusió anotant a la figura 13 la precisió, el *recall*, i la puntuació F1 per a cada càmera en el conjunt de test de forma individual.

A la figura 13 es pot veure que, com ja s'havia pogut observar a la matriu de confusió, les càmeres 4 i 5 presenten una precisió menor a la resta.

| Càmera | Precisió(%) | Recall (%) | Puntuació F1 (%) |
|--------|-------------|------------|------------------|
| CAM1   | 82.21       | 67.59      | 74.19            |
| CAM2   | 68.98       | 82.07      | 74.96            |
| CAM3   | 77.27       | 68.46      | 72.60            |
| CAM4   | 54.01       | 64.35      | 58.73            |
| CAM5   | 49.37       | 66.10      | 56.52            |
| CAM6   | 80.65       | 67.87      | 73.71            |

**Figura 13:** *Precisió, Recall i Puntuació F1 de cada càmera amb backbone SwinV2.*

Observant un parell de moments aleatoris de les càmeres 2, 4 i 5; dels dos vídeos que conformen el conjunt de test, es pot observar que les perspectives són força similars. El que demostra que el model presenta dificultats en distingir quina és la millor càmera quan els dos punts de vista són força semblants.

A la figura 14 es pot veure un exemple de dos fotogrames on el model s'ha equivocat i ha seleccionat la càmera 2 en comptes de la 5, on clarament es pot veure que són molt similars.




**Figura 14:** Càmeres 2 i 4 del vídeo 0000 en el conjunt de test.

També s'ha decidit valorar si per a la versió del model entrenat amb MobileNetV3 hi havia dificultats amb alguna càmera en específic, per fer-ho, s'ha creat una matriu de confusió amb els resultats obtinguts amb aquest *backbone*.

A la figura 15 es pot veure que el model amb MobileNetV3 ha encertat correctament la majoria de moments on s'ha utilitzat les càmeres 1 i 2, però a partir de la càmera 3 es nota com es redueixen dràsticament el número d'encerts respecte els vistos amb el backbone SwinV2.

El que més destaca de la matriu de confusió és que, les càmeres 4 i 5, amb les quals el model amb el backbone més potent tenia problemes, en aquest presenten més prediccions errònies que encertades, i es pot observar que en la majoria de casos on s'utilitzaven aquestes càmeres s'ha seleccionat la càmera 2.

Com s'ha vist abans, la càmera 2 és força similar a les 4 i 5 per tant, la dificultat en distingir fotogrames força similars és més present en el model entrenat amb aquest *backbone*.



**Figura 15:** *Matriu de confusió del model amb backbone MobileNetV3*

## 2. Conclusions i treballs futurs

En aquest treball s'ha pogut replicar exitosament l'arquitectura proposada a *Improving Multi-Camera View Recommendation with Temporal and Camera Embeddings*<sup>[3]</sup>, obtenint un model capaç de seleccionar la millor càmera a utilitzar en un moment concret en un entorn multicàmera.

Els resultats trobats corresponen amb els observats al paper prèviament esmentat, diferenciant-se únicament en el temps d'entrenament menor, que pot ser explicat per l'augment de la mida de *batch* i l'ús de versions petites de models més grans com a *backbone*.

L'*accuracy* i precisió del model obtingut mostren que la majoria de prediccions realitzades són correctes, tot i que presenta dificultats quan les diferents càmeres mostren perspectives similars.

Aquesta limitació fa que el model no sigui adequat en escenaris on la diferència entre una càmera i una altra són molt petites.

Per altra banda, la precisió obtinguda és superior a la reportada en el model presentat a *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows*<sup>[19]</sup> i el temps d'entrenament requerit és bastant més petit.

Addicionalment, s'ha entrenat una altra versió del model que utilitza *mobilenetv3\_small\_100.lamb\_in1*<sup>[5]</sup> en l'extractor de característiques en comptes de *swinv2\_tiny\_window8\_256*<sup>[4]</sup> per veure si els resultats favorables obtinguts es mantenen amb un backbone que requereix menys recursos.

Si bé el temps d'entrenament ha sigut menor, l'*accuracy*, precisió, sensitivitat i puntuació F1 demostren que el canvi de *backbone* impacta negativament en el model.

A més a més, els problemes que presentava el model amb el backbone més potent en prendre la decisió correcte quan els fotogrames candidats són força similars s'agregen amb aquesta versió.

En conclusió, en aquest projecte s'ha obtingut un model més precís que el presentat en *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows*<sup>[19]</sup>, que requereix menys temps d'entrenament i recursos. Dels dos backbones avaluats, la millor versió del model ha sigut la que utilitza *swinv2\_tiny\_window8\_256*<sup>[4]</sup> demostrant la importància del backbone en aquesta arquitectura.

Respecte a la planificació, a l'inici de la implementació del model es va decidir treballar amb una metodologia que consistia en descomprimir els fotogrames de cada vídeo de l'arxiu *tar* on estaven presents a mesura que s'anaven utilitzant.

El procés va causar un *bottleneck* en l'entrenament que, sumat a la poca experiència amb pytorch, ha obligat a renunciar a quantificar el backbone del feature extractor com es tenia previst en un principi.

Sobre la sostenibilitat del projecte, en prescindir dels transformadors temporals i de context utilitzats en altres propostes, s'aconsegueix reduir els recursos i temps necessaris per a l'entrenament del model.

L'impacte social també és reduït, com el model desenvolupat només és capaç d'escollir entre diferents perspectives quan es vol realitzar un canvi de plànol, no posa en perill la feina de cap editor sinó que l'agilitza.

Gràcies a això, els professionals es poden centrar més en determinar on realitzar una transició entre càmeres més que en pensar quin angle seria el correcte.

Adicionalment, la precisió del model és lluny de ser perfecta i presenta dificultats quan els diferents punts de vista són similars, el que implica la necessitat d'una persona que supervisi les eleccions i pugui actuar quan el fotograma escollit no és el més indicat.

Respecte a l'ètica, el projecte no promou comportaments ètics o no ètics, el model desenvolupat simplement selecciona el punt de vista més indicat en cada moment en un entorn multicàmera. Per tant, la moralitat de l'ús dels resultats obtinguts recau intrínsecament en l'usuari.

Finalment, parlant de les línies de treball a futur, aquest treball deixa la porta oberta a provar com es comporta el model desenvolupat amb vídeos multicàmera fora de les categories presents al TVMCE *dataset*, com es fa a *Pseudo Dataset Generation for Out-of-Domain Multi-Camera View Recommendation*<sup>[2]</sup>, i veure si generalitza bé.

Relacionat amb aquest últim paper, es podria realitzar *fine-tuning* del model desenvolupat amb entorns multicàmera simulats per a especialitzar-lo en un àmbit específic, com per exemple el rodatge d'una pel·lícula.

Aquesta idea es basa en els següents fets:

- Molts canvis de pla en un vídeo són el resultat de canvis de càmera.
- En un entorn multicàmera, les càmeres són estacionàries i són responsables de gravar perspectives a diferents escales (des de generals a més properes a una acció).

Per tant, és possible recrear un entorn multicàmera a partir d'un vídeo lineal prenent cada perspectiva mostrada com una càmera diferent, i definir els diferents candidats per a cada moment en funció de la similitud que presenten.

Per a la realització d'aquesta idea, es podria consultar alguna col·lecció de pel·lícules de domini públic, com *WikiFlix*, i descarregar-ne unes quantes que pertanyin a un gènere concret.

Un cop creat el conjunt de dades, s'haurien de dividir els vídeos en fotogrames per a poder treballar amb ells.

Obtingudes les imatges, per a cada pel·lícula s'hauria de realitzar *clustering* sobre els seus fotogrames per a dividir-los en grups, i assignar a cada grup una ID.

Aquest identificador representaria una càmera en un entorn multi-càmera, és a dir, una *pseudo-càmera*.

Un cop simulat l'entorn multicàmera, només caldria definir els fotogrames candidats per a cada moment, per fer-ho es podria aplicar *cosine-similarity* sobre totes les imatges i considerar com a candidats els que més s'assemblin de cada grup al fragment utilitzat per a un moment concret a la pel·lícula.

Amb el mètode descrit, es podria realitzar fine-tuning sobre el model creat en aquest treball per a que s'especialitzi en seleccionar el punt de vista més indicat a mostrar en el rodatge d'una pel·lícula, mitjançant vídeos lineals.

L'únic inconvenient d'aquesta metodologia és la necessitat de posseir les gravacions de cada càmera amb les que s'ha rodat almenys una pel·lícula en un entorn multicàmera real per a valorar el model, degut a que la selecció de fotogrames de l'entorn simulat, en no venir d'una selecció real, poden portar a resultats erronis que facin semblar al model més o menys eficaç del que en realitat és.

A part d'especialitzar el model, també es podria utilitzar una versió no tiny del *backbone* per veure com impactaria en el temps d'entrenament i els resultats.

En aquest treball s'ha arribat a veure com canviar un *backbone* potent com *swinv2\_tiny\_window8\_256*<sup>[4]</sup> per un altre més lleuger empitjora el model resultant, per tant, es podria estudiar si canviar-lo per un de més potent ajudaria a millorar la precisió de les eleccions fetes.

Una altra forma de millorar el model creat, seria incorporar al feature vector l'audio dels diferents vídeos, el que podria ajudar al model a identificar amb més eficiència l'acció important en cada escenari gràcies a la informació extra.

La principal dificultat en la implementació d'aquesta millora és la manca de conjunts de dades amb diferents perspectives en un entorn multicàmera i audio incorporat.

La pràctica de crear models que no només utilitzin els elements visuals d'un vídeo, sinó també els auditis, és utilitzada en models enfocats a identificar esdeveniments, com el que s'explora a *Multimodal Attentive Fusion Network for audio-visual event recognition*<sup>[25]</sup>.

Degut a l'ús que se li dona a l'audio en el paper citat, una gran millora que podria aportar la incorporació d'àudio al model seria dotar-li de més informació sobre els esdeveniments tenint lloc a una escena, el que l'ajudaria a fer eleccions més informades.

També es podria estudiar com es comporta aquesta arquitectura si, en comptes d'utilitzar múltiples càmeres, s'emprés un únic pla general i aquest es fragmentés en diferents finestres, semblant al que es fa a *Real Time GAZED: Online Shot Selection and Editing of Virtual Cameras From Wide-Angle Monocular vídeo Recording*<sup>[8]</sup>.

Per a poder implementar aquesta idea, es podria dividir el pla general en minifinestres i assignar-li a cadascuna una ID, d'aquesta forma simulant un entorn multicàmera amb el que el model creat en aquest projecte podria treballar.

Això ens podria mostrar si l'arquitectura no només es pot aplicar a entorns multicàmera, sinó també per a produir vídeos on els diferents plànols es deriven de fragmentar un punt de vista general estàtic en diversos petits centrats en una zona específica de l'escenari, com es fa en produccions de baix pressupost.

Finalment, es podria utilitzar aquest model en conjunt amb un altre que, en comptes de seleccionar quin és el millor punt de vista en un entorn multicàmera, s'enfoqui en decidir en quin moment del vídeo s'ha de canviar de pla; com el que es proposa a *When and How to Cut Classical Concerts? A Multimodal Automated video Editing Approach*<sup>[16]</sup>.

### 3. Glossari

- **Multicàmera:** Mètode de rodatge on varies càmeres graven una mateixa escena des de múltiples punts de vista i després s'utilitzen els millors angles en el vídeo final.
- **Self-attention:** Un mecanisme força utilitzat en models de *machine learning* per a evaluar la importància dels diferents elements d'una seqüència de dades respecte els altres.
- **Transformer:** Model de *Deep Learning* que segueix les relacions entre els diferents elements en una seqüència de dades per aprendre el context.
- **Embedding:** Tècnica molt utilitzada en machine learning on es transformen inputs complexos, com per exemple paraules, en vectors numèrics amb els quals es pot treballar.
- **MLP:** Són les sigles de *Mult Layer Perceptron*, aquest terme s'utilitza per definir xarxes neuronals *feedforward* compostes per neurones totalment connectades amb funcions d'activació no lineals. Són conegudes per la seva capacitat de distingir dades que no són separables linealment.
- **TVMCE dataset:** Conjunt de dades utilitzat en aquest treball per entrenar el model, presentat per primer cop en *Temporal and Contextual Transformer for Multi-Camera Editing of TV Show*<sup>[19]</sup>
- **Backbone:** Extractor de característiques utilitzat en models de *Deep Learning* per a extreure característiques d'imatges.

## 4. Bibliografia

1. Rao, A., Jiang, X., Wang, S., Guo, Y., Liu, Z., Dai, B., Pang, L., Wu, X., Lin, D., & Jin, L. (2022). *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows* (arXiv:2210.08737). arXiv.  
<https://doi.org/10.48550/arXiv.2210.08737>
2. Lee, K.-Y., Zhou, Q., & Nahrstedt, K. (2024). *Pseudo Dataset Generation for Out-of-Domain Multi-Camera View Recommendation* (arXiv:2410.13585). arXiv. <https://doi.org/10.48550/arXiv.2410.13585>
3. Lee, K.-Y., Zhou, Q., & Nahrstedt, K. (2025). Improving Multi-Camera View Recommendation with Temporal and Camera Embedding. 2025 *21st International Conference on Intelligent Environments (IE)*, 1-5.  
<https://doi.org/10.1109/IE64880.2025.11130132>
4. Liu, Z., Hu, H., Lin, Y., Yao, Z., Xie, Z., Wei, Y., Ning, J., Cao, Y., Zhang, Z., Dong, L., Wei, F., & Guo, B. (2021, novembre 18). *Swin Transformer V2: Scaling Up Capacity and Resolution*. arXiv.Org. <https://arxiv.org/abs/2111.09883v2>
5. Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., Wang, W., Zhu, Y., Pang, R., Vasudevan, V., Le, Q. V., & Adam, H. (2019). *Searching for MobileNetV3* (arXiv:1905.02244). arXiv. <https://doi.org/10.48550/arXiv.1905.02244>
6. Chouksey, A., Rajan, A. K., Gurjar, V., Tiwari, R., & Mishra, P. K. (2026). The green paradox: The climate, environmental, and sustainability implications of artificial intelligence. *Global Environmental Change Advances*, 6, 100029.  
<https://doi.org/10.1016/j.gecadv.2025.100029>
7. Reisz, K. (s.d.). *The technique of film editing*.
8. Achary, S., Girmaji, R., Deshmukh, A. A., & Gandhi, V. (2024). Real Time GAZED: Online Shot Selection and Editing of Virtual Cameras from Wide-Angle

Monocular Video Recordings. *2024 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 4096-4104. <https://doi.org/10.1109/WACV57701.2024.00406>

9. He, K., Zhang, X., Ren, S., & Sun, J. (2015). *Deep Residual Learning for Image Recognition* (arXiv:1512.03385). arXiv. <https://doi.org/10.48550/arXiv.1512.03385>

10. Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 248-255. <https://doi.org/10.1109/CVPR.2009.5206848>

11. Bai, J., Xia, M., Fu, X., Wang, X., Mu, L., Cao, J., Liu, Z., Hu, H., Bai, X., Wan, P., & Zhang, D. (2025). *ReCamMaster: Camera-Controlled Generative Rendering from A Single Video* (arXiv:2503.11647). arXiv. <https://doi.org/10.48550/arXiv.2503.11647>

12. Sobchyshak, O., Berrezueta-Guzman, S., & Wagner, S. (2026). Pushing the boundaries of immersion and storytelling: A technical review of Unreal Engine. *Displays*, 91, 103268. <https://doi.org/10.1016/j.displa.2025.103268>

13. Arnab, A., Dehghani, M., Heigold, G., Sun, C., Lučić, M., & Schmid, C. (2021). *ViViT: A Video Vision Transformer* (arXiv:2103.15691). arXiv. <https://doi.org/10.48550/arXiv.2103.15691>

14. Liu, Z., Ning, J., Cao, Y., Wei, Y., Zhang, Z., Lin, S., & Hu, H. (2021). *Video Swin Transformer* (arXiv:2106.13230). arXiv. <https://doi.org/10.48550/arXiv.2106.13230>

15. Kay, W., Carreira, J., Simonyan, K., Zhang, B., Hillier, C., Vijayanarasimhan, S., Viola, F., Green, T., Back, T., Natsev, P., Suleyman, M., & Zisserman, A. (2017). *The Kinetics Human Action Video Dataset* (arXiv:1705.06950). arXiv. <https://doi.org/10.48550/arXiv.1705.06950>

16. Gonzálbez-Biosca, D., Cabacas-Maso, J., Ventura, C., & Benito-Altamirano, I. (2025). When and How to Cut Classical Concerts? A Multimodal Automated Video Editing Approach. *Proceedings of the 3rd International Workshop on Multimedia Content Generation and Evaluation: New Methods and Practice, McGE '25*, 98-106. <https://doi.org/10.1145/3746278.3759387>
17. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023). *Attention Is All You Need* (arXiv:1706.03762). arXiv. <https://doi.org/10.48550/arXiv.1706.03762>
18. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., & Guo, B. (2021). *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows* (arXiv:2103.14030). arXiv. <https://doi.org/10.48550/arXiv.2103.14030>
19. Rao, A., Jiang, X., Wang, S., Guo, Y., Liu, Z., Dai, B., Pang, L., Wu, X., Lin, D., & Jin, L. (2022). *Temporal and Contextual Transformer for Multi-Camera Editing of TV Shows* (arXiv:2210.08737). arXiv. <https://doi.org/10.48550/arXiv.2210.08737>
20. *Pie Chart Creator*. (s.d.). Recuperat 17 de maig de 2026, de <https://geographyfieldwork.com/PieChartCreator.html>
21. Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., & Gimelshein, N. (s.d.). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*.
22. Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C., & Fei-Fei, L. (2014, setembre 1). *ImageNet Large Scale Visual Recognition Challenge*. arXiv.Org. <https://arxiv.org/abs/1409.0575v3>
23. Wightman, R., Raw, N., Soare, A., Arora, A., Ha, C., Reich, C., Guan, F., Kacmarzyk, J., MrT23, Mike, SeeFun, Contrastive, Rizin, M., Hyeongchan

Kim, Kertész, C., Dushyant Mehta, Cucurull, G., Kushajveer Singh, Hankyul, ... Uchida,

Y. (2023). *rwightman/pytorch-image-models: V0.8.10dev0 Release* (Versió

v0.8.10dev0) [Programari]. Zenodo. <https://doi.org/10.5281/ZENODO.4414861>

24. Loshchilov, I., & Hutter, F. (2019). *Decoupled Weight Decay*

*Regularization* (arXiv:1711.05101). arXiv. <https://doi.org/10.48550/arXiv.1711.05101>

25. Brousmiche, M., Rouat, J., & Dupont, S. (2022). Multimodal

Attentive Fusion Network for audio-visual event recognition. *Information Fusion*, 85,

52-59. <https://doi.org/10.1016/j.inffus.2022.03.001>